

ANDRÉ LIMA ALAMBERT



Estudo da performance do algoritmo genético na resolução do Fluxo de Potência Ótimo multiobjetivo com inserção de renováveis.

Relatório Final da disciplina de Projeto de Formatura I, apresentado à Escola Politécnica da Universidade de São Paulo

Área de Concentração: Sistemas de Potência

Orientador: Prof. Dr. Silvio Giuseppe

São Paulo
(2025)

RESUMO

Este trabalho apresenta o desenvolvimento do TCC I, cujo objetivo é estudar a aplicação de algoritmos meta-heurísticos na resolução do problema do Fluxo de Potência Ótimo (FPO) em formulação multiobjetivo com inserção de renováveis. Inicialmente, é realizada uma revisão teórica sobre as principais formulações do FPO, abordando funções objetivo típicas, como minimização de custos, perdas e desvios de tensão, bem como as restrições elétricas e operacionais do sistema. Em seguida, são discutidas as limitações dos métodos convencionais de otimização e introduzidos algoritmos meta-heurísticos amplamente utilizados na literatura, com ênfase no Algoritmo Genético (AG), escolhido como técnica principal deste trabalho em razão de sua flexibilidade, robustez frente à não convexidade e facilidade de tratamento de problemas multiobjetivo. O relatório também descreve o mapeamento entre as variáveis do FPO e a estrutura do AG, além da modelagem teórica da geração renovável e sua integração no software *OpenDSS*, que atuará como motor de cálculo do fluxo de potência na etapa experimental do TCC II. Por fim, são apresentados resultados parciais obtidos a partir de simulações preliminares, envolvendo análise de perfis de tensão, perdas e comportamento do sistema frente a variações operacionais, os quais validam o ambiente computacional, a modelagem da geração renovável, e abrem caminho para a etapa de otimização completa a ser desenvolvida no próximo semestre.

Palavras-Chave: Fluxo de Potência Ótimo. Algoritmo Genético. Otimização Multiobjetivo. Geração Renovável. *OpenDSS*.

ABSTRACT

This work presents the development of TCC I, whose objective is to study the application of metaheuristic algorithms to solve the Optimal Power Flow (OPF) problem in a multiobjective formulation with the insertion of renewable sources. Initially, a theoretical review of the main OPF formulations is carried out, addressing typical objective functions such as cost minimization, loss reduction, and voltage deviation minimization, as well as the electrical and operational constraints of the system. Next, the limitations of conventional optimization methods are discussed, and metaheuristic algorithms widely used in the literature are introduced, with emphasis on the Genetic Algorithm (GA), selected as the main technique of this work due to its flexibility, robustness with respect to nonconvexity, and suitability for handling multiobjective problems. The report also describes the mapping between OPF variables and the GA structure, as well as the theoretical modeling of renewable generation and its integration into the *OpenDSS* software, which will act as the power flow calculation engine in the experimental stage of TCC II. Finally, partial results obtained from preliminary simulations are presented, including voltage profile analysis, loss evaluation, and system behavior under operational variations, which validate the computational environment and the renewable generation modeling, and pave the way for the complete optimization stage to be developed in the next semester.

Keywords: Optimal Power Flow. Genetic Algorithm. Multiobjective Optimization. Renewable Generation. *OpenDSS*.

SUMÁRIO

1	INTRODUÇÃO.....	7
1.1	CONTEXTO E MOTIVAÇÃO.....	7
1.2	OBJETIVOS DO TRABALHO.....	8
1.3	ESCOPO E PRÓXIMOS PASSOS.....	8
1.4	ESTRUTURA DO RELATÓRIO.....	9
2	FUNDAMENTAÇÃO TEÓRICA.....	10
2.1	O QUE É O FLUXO DE POTÊNCIA ÓTIMO.....	10
2.1.1	FLUXO DE POTÊNCIA.....	10
2.1.2	MODELO DE INJEÇÃO NAS BARRAS (BIM).....	11
2.1.3	FLUXO DE POTÊNCIA ÓTIMO.....	12
2.1.3.1	FUNÇÃO OBJETIVO.....	12
2.1.3.2	RESTRIÇÕES.....	13
2.2	MÉTODOS CONVENCIONAIS PARA RESOLVER O FPO.....	13
2.2.1	PROGRAMAÇÃO LINEAR (PL).....	13
2.2.2	PROGRAMAÇÃO QUADRÁTICA (PQ).....	14
2.2.3	NEWTON-RAPHSON (NR).....	14
2.2.4	DESVANTAGEM DOS MÉTODOS CLÁSSICOS.....	15
2.3	ALGORITMOS MET-HEURÍSTICOS.....	15
2.3.1	ALGORITMO GENÉTICO.....	16
2.3.2	OTIMIZAÇÃO POR ENXAME DE PARTÍCULAS (PSO).....	16
2.3.3	ALGORITMO EVOLUTIVO DIFERENCIAL (AED).....	17
3	METODOLOGIA.....	18
3.1	ALGORITMO GENÉTICO.....	18
3.1.1	O AG EXPLICADO.....	19
3.1.2	OPERADORES GENÉTICOS.....	20
3.1.3	MAPEAMENTO DAS VARIÁVEIS DO FPO PARA O AG.....	22
3.1.3.1	FUNÇÕES OBJETIVO E RESTRIÇÕES.....	22
3.1.3.2	REPRESENTAÇÃO E CODIFICAÇÃO DAS VARIÁVEIS NO AG...	24
3.2	MODELAGEM DA GERAÇÃO EÓLICA.....	25
3.2.1	CONVERSÃO DA VELOCIDADE DO VENTO EM POTÊNCIA.....	25
3.3	OPENDSS E A INTERFACE EM PYTHON PY-DSS-INTERFACE.	27
3.3.1	GERAÇÃO EÓLICA NO OPENDSS.....	28
4	RESULTADOS.....	29
4.1	CASO 1 - GERAÇÃO NAS BARRAS, SIMULAÇÃO ESTATICA.....	29
4.2	CASO 2 - GERAÇÃO EM N4, SIMULAÇÃO DINÂMICA.....	30
5	PRÓXIMOS PASSOS.....	33
6	CONCLUSÃO PARCIAL.....	34

1 INTRODUÇÃO

1.1 CONTEXTO E MOTIVAÇÃO

Nas duas últimas décadas, a complexidade dos sistemas elétricos de potência cresceu significativamente devido a vários fatores, sendo os principais um aumento na demanda de energia e a imprevisibilidade da crescente geração renovável. Essa transição exige técnicas de planejamento e operação capazes de lidar com incertezas e múltiplos critérios de decisão. O Fluxo de Potência Ótimo (FPO) desempenha um papel central nesse processo: é um problema de otimização que almeja determinar variáveis de controle que otimizem critérios operacionais enquanto satisfazem as equações do fluxo de potência e restrições de segurança. As equações do FPO são não lineares e não convexas, ou seja, é um problema que admite múltiplas soluções ótimas locais para a função objetiva, o que torna mais difícil encontrar a solução ótima global e se torna um problema computacional NP-complexo, sendo computacionalmente inviável achar soluções viáveis em redes muito grandes. [\[1\]](#) [\[2\]](#)

As abordagens tradicionais do FPO, como os métodos de Newton-Raphson, Gauss-Seidel, programação linear, entre outros, têm valor em muitos cenários, mas apresentam limitações quando confrontadas com linearidade não acentuada, múltiplos objetivos e componentes probabilísticos. Consequentemente, abordagens estocásticas vêm ganhando espaço na literatura nos últimos anos, que é o caso do Fluxo de Potência Ótimo Bayesiano (FPO-B) e do Fluxo de Potência Ótimo Probabilístico (FPO-P), abordagens reconhecidas pela sua capacidade de alcançar múltiplos objetivos simultaneamente, como redução de perdas, minimização de custos de geração, e diminuição de desvios de tensão e de emissões de carbono. [\[3\]](#) [\[4\]](#)

Cálculos de FPO são uma parte crucial do gerenciamento de sistemas de potência, particularmente para o mercado de energias limpas. Os cálculos precisam ser rápidos e precisos para acompanhar as constantes mudanças da demanda e da rede. Ainda que a adoção crescente de energias renováveis traga muitas vantagens, incluindo menor custo de operação e menor impacto ambiental em comparação com as fontes tradicionais de energia, adiciona uma complexidade maior no

planejamento e na operação das redes elétricas. Muitos estudos recentes se preocupam em resolver o FPO integrado com energias renováveis. [\[5\]](#) [\[6\]](#)

1.2 OBJETIVOS DO TRABALHO

O objetivo do TCC I foi estudar, comparar e iniciar a modelagem para a aplicação de algoritmos meta-heurísticos na resolução do FPO multiobjetivo com inserção de renováveis, dividido em:

- Revisar o estado da arte das formulações do FPO e das principais técnicas de solução, convencionais e meta-heurísticas.
- Identificar limitações dos métodos clássicos e oportunidades para meta-heurísticas.
- Justificar a escolha do Algoritmo Genético (AG) como técnica principal de resolução do FPO deste trabalho e definir a codificação teórica das variáveis do FPO em variáveis do AG.
- Estudar e realizar testes com o software OpenDSS, o qual será utilizado na modelagem do FPO e da geração renovável, e servirá como motor de cálculo do Fluxo de Potência.
- Definir a metodologia de integração entre o AG e OpenDSS, cuja implementação será realizada no TCC II.

1.3 ESCOPO E PRÓXIMOS PASSOS

O escopo do TCC I inclui levantamento bibliográfico, formulação matemática do problema, introdução e discussão dos algoritmos de solução presentes na literatura, definição da metodologia experimental, e aprendizado e simulações iniciais de Fluxo de Potência em casos de teste IEEE com o software OpenDSS. A continuação, isto é, os experimentos computacionais extensivos, incluindo integração AG+OpenDSS, foram planejados para o TCC II.

1.4 ESTRUTURA DO RELATÓRIO

O relatório final está organizado da seguinte forma: na Seção 2 apresenta-se a fundamentação teórica (modelos de FP e FPO, funções objetivo, restrições e revisão de métodos); a Seção 3 descreve a metodologia adotada e o plano experimental; a Seção 4 compila resultados parciais e discussão; a Seção 5 detalha os próximos passos planejados para o TCC II (integração AG + OpenDSS, cenários de energia renovável e otimização de expansão); a Seção 6 apresenta a conclusão parcial; por fim, são listadas as referências consultadas.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 O QUE É O FLUXO DE POTÊNCIA ÓTIMO?

2.1.1 FLUXO DE POTÊNCIA

Antes de discorrer sobre o Fluxo de Potência Ótimo (FPO), é importante explicar o problema do Fluxo de Potência (FP), pois o FPO é uma extensão do FP. Para alcançar esse objetivo, o primeiro passo é visualizar a rede elétrica como um grafo. As redes elétricas incluem dois componentes principais: nós, para representar objetos importantes da rede (tais como geradores, carga e subestações), e linhas de transmissão ou distribuição que conectam esses nós. Dessa forma, é extremamente natural modelar a rede elétrica como um grafo, onde os nós da rede e as linhas de transmissão correspondem, respectivamente, aos nós e às arestas do grafo. A rede pode ser modelada como um grafo orientado $G_D(N, E)$ ou não orientado $G_U(N, E \cup E^R)$, onde N , E , E^R são, respectivamente, o conjunto dos nós do grafo, as arestas do grafo de orientação direta e as arestas de orientação reversa.




Figura 1 – Grafo orientado representando uma rede de 14 nós (esquerda) e grafo não orientado representando uma rede de 30 nós (direita). ([A Gentle Introduction to Power Flow · Invenia Blog](#))

Existem duas formulações básicas para o FP: o Modelo de Injeção nas Barras (BIM), baseado no modelo de grafo não orientado da rede elétrica e o Modelo de Fluxo nos Ramos (BFM), baseado no modelo de grafo orientado da rede. Para uma mesma

rede, resolver o Fluxo de Potência em qualquer uma das formulações conduz aos mesmos resultados. Como o objetivo é explicar o FP, apresento apenas a formulação BIM e introduzo o FP a partir dela.

2.1.2 MODELO DE INJEÇÃO NAS BARRAS (BIM)

Para cada nó i , denotamos por N_i o conjunto de nós diretamente conectados ao nó i . Para cada nó, temos S_i^{gen} , potência gerada que flui para o nó, S_i^{load} , potência que flui para toda carga conectada ao nó, $S_i = S_i^{gen} - S_i^{load}$, potência líquida injetada no nó, e $S_i^{trans} = S_{ij} + S_{ik} + S_{il}$, potência que flui do nó para os nós adjacentes. A conservação de energia estabelece que $S_i = S_i^{gen} - S_i^{load} = S_i^{trans}$, $\forall i \in N$. Dessa forma, a formulação BIM se apresenta na forma concisa como $S_i = \sum_{j \in N_i} Y_{ij}^* (|V_i|^2 - V_i V_j^*)$ $\forall i \in N$, onde Y_{ij} é a admitância entre os nós i e j e V_i e V_j são as tensões nodais.




Figura 2 - Balanceamento de potência de um nó conectado a 3 nós adjacentes, a um gerador e a uma carga. ([A Gentle Introduction to Power Flow · Invenia Blog](#))

Dadas certas variáveis de entrada, o problema do Fluxo de Potência consiste em achar uma solução única para o sistema de potência. As equações do modelo BIM definem um sistema não linear complexo com $2N$ equações reais e $4N$ variáveis reais: $\{p_i, q_i, v_i, \delta_i\}_{i=1}^N$, onde $S_i = p_i + jq_i$ e $V_i = v_i \angle \delta_i$. O problema do Fluxo de Potência consiste em, para cada nó, especificar duas dentre as quatro variáveis reais e usar as duas equações restantes para determinar as outras variáveis.

2.1.3 FLUXO DE POTÊNCIA ÓTIMO

Enquanto o FP almeja encontrar um estado possível de operação enquanto satisfaz equações relacionadas a geração, carga e linhas de transmissão, o FPO combina a isso uma ou mais grandezas que se deseja maximizar ou minimizar através de funções objetivas. Em suas formulações mais gerais, o FPO determina os melhores pontos de operação para minimizar custos, reduzir perdas, melhorar perfis de tensão, minimizar emissões, ou combinar múltiplos objetivos simultaneamente. Algumas variantes do FPO a serem consideradas:

- FPO estático: visa identificar as condições ótimas de operação para um sistema de potência num tempo específico, para uma carga fixa.
- FPO dinâmico: determina os melhores pontos de operação durante um intervalo de tempo contínuo, considerando variações de carga.
- FPO CA: produz soluções exatas ao modelar precisamente as características não lineares de sistemas de corrente alternada.
- FPO CC: simplifica o FPO através de uma aproximação linear do sistema de potência, assumindo níveis de tensão constantes e desconsiderando potência reativa.

2.1.3.1 FUNÇÃO OBJETIVO

A função objetivo é a expressão matemática que encontra a melhor forma de operar um sistema de potência aumentando ou diminuindo algum critério enquanto permanece dentro dos limites operacionais e físicos. Entre as mais comuns, temos:

- Minimização dos custos de geração:

$$\text{Min } f = \sum_{i=1}^{N_G} f_i(P_{Gi}) = \sum_{i=1}^{N_G} (a_i P_{Gi}^2 + b_i P_{Gi} + c_i)$$

- Minimização das perdas:

$$\text{Min } f = \sum_{i,j \in N_b} g_{ij} (V_i^2 + V_j^2 - V_i V_j \cos \theta_{ij})$$

- Melhoria do perfil de tensão:

$$\text{Min } f = \sum_{i=1}^{N_L} |V_{Li} - V_{ref}|$$

2.1.3.2 RESTRIÇÕES

As restrições são cruciais para garantir a segurança e eficiência do sistema de potência. Elas podem ser caracterizadas em restrições de igualdade e restrições de desigualdade. Alguns exemplos de restrições:

- Restrições de igualdade:

$$P_{Gi} - P_{Di} - V_i \sum_{j=1}^{N_b} V_j (G_{ij} \cos \phi_{ij} + B_{ij} \sin \phi_{ij}) = 0$$

$$Q_{Gi} - Q_{Di} - V_i \sum_{j=1}^{N_b} V_j (G_{ij} \sin \phi_{ij} + B_{ij} \cos \phi_{ij}) = 0$$

- Restrições de desigualdade:

$$P_{Gi}^{min} \leq P_{Gi} \leq P_{Gi}^{max}$$

$$Q_{Gi}^{min} \leq Q_{Gi} \leq Q_{Gi}^{max}$$

- Limites de tensão e térmico:

$$V_i^{min} \leq V_i \leq V_i^{max}$$

$$P_{line}^{ij} \leq P_{line}^{ij,max}$$

2.2 MÉTODOS CONVENCIONAIS PARA RESOLVER O FPO

2.2.1 PROGRAMAÇÃO LINEAR (PL)

A função objetiva e as restrições do FPO são naturalmente não lineares, mas métodos que utilizam programação linear resolvem o problema através de linearização. No estudo [7], um algoritmo baseado em sucessiva programação linear é introduzido. O algoritmo utiliza aproximações sensíveis de segunda ordem para tornar o método mais acurado e rápido. Esta abordagem é particularmente benéfica para sistemas onde as funções de custo de geração são similares, o que causa tempo de convergência alto em métodos tradicionais. Não obstante, métodos que usam programação linear em geral requerem muitas iterações para obter resultados precisos, levando a um aumento no esforço computacional. Além disso, restrições extremamente não lineares podem afetar significativamente a qualidade das aproximações lineares.

2.2.2 PROGRAMAÇÃO QUADRÁTICA (PQ)

Técnica de otimização caracterizada por uma função objetiva formulada como uma equação quadrática enquanto todas as restrições são lineares. Em [8], é mostrado um modelo quadrático para o FPO, evidenciando funções e restrições que podem ser alteradas para permitir um controle personalizado do sistema. O método utiliza análise de sensibilidade e ajustes de restrições para prover soluções ótimas globais. Em [9], uma nova abordagem que utiliza PQ para redes inteligentes de distribuição é introduzida. Esta abordagem foi comparada com formulações padrões não lineares, formulações quadráticas, e formulações linearizadas. O estudo foca em duas aplicações: otimizar o gerenciamento de unidades de geração distribuída para maximizar o uso de energia renovável e minimizar perdas de energia através de capacitores. A performance do algoritmo supera métodos tradicionais, provendo tempo computacional menor e soluções de maior qualidade.

2.2.3 NEWTON-RAPHSON (NR)

O método de Newton-Raphson resolve problemas não lineares linearizando-os iterativamente. Começa com uma estimativa inicial e utiliza a derivada da função para gerar uma aproximação linear, melhorando o resultado a cada iteração. O método de NR é amplamente reconhecido pela sua convergência quadrática em direção à solução, porém depende de um bom palpite inicial para a solução.

NR é extensivamente utilizado na resolução de equações não lineares de fluxo de potência. O estudo [10] descreve um algoritmo baseado em NR com fatores de sensibilidade que melhoram o despacho de emissão em tempo real em sistemas de potência.

O método NR tradicional para análise de FP pode ser melhorado substituindo as equações de desbalanço de potência por equações de desbalanço de corrente não lineares, simplificando a matriz Jacobiana [11]. Simulações em diferentes sistemas de testes IEEE mostram que o método simplificado converge tão bem quanto o método tradicional, porém demanda menos iterações e, consequentemente, um tempo computacional menor para a realização dos cálculos.

2.2.4 DESVANTAGENS DOS MÉTODOS CLÁSSICOS

Apesar dos avanços no desenvolvimento dos métodos clássicos de otimização, eles ainda enfrentam diversas barreiras que limitam sua performance em situações do mundo real. Dentre elas, se destacam:

- **Armadilha em ótimos locais:** os métodos vão ficar preso em ótimos locais e não encontrarão a solução ótima global ao resolver problemas não convexos.
- **Requerem linearização:** alguns métodos clássicos envolvem linearização de problemas para tornar sua resolução mais fácil, porém aspectos importantes da dinâmica não linear dos sistemas de potência podem se perder.
- **Requerem diferenciação:** técnicas clássicas de FPO utilizam derivadas de primeira e segunda ordem de funções objetivas e restrições, o que obriga que essas funções sejam diferenciáveis.
- **Convergência lenta:** a velocidade de convergência para a solução ótima é lenta, particularmente para sistemas complexos de larga escala, o que indica que métodos tradicionais são ineficazes para processos que exigem rápida tomada de decisão.
- **Inflexibilidade ao lidar com problemas multiobjetivos:** Abordagens convencionais são frequentemente construídas para lidar com problemas de uma única função objetivo e geralmente requerem ajustes adicionais e formulações complexas para lidar com problemas com mais de uma função objetivo.
- **Habilidade limitada para lidar com incertezas:** métodos clássicos geralmente categorizam as entradas como determinísticas e fixas, o que é inviável para sistemas de potência repletos de incertezas, como recursos renováveis variáveis ou cargas imprevisíveis.

Esses problemas evidenciam as limitações das abordagens convencionais do FPO e advogam para a adoção de técnicas avançadas, como as meta-heurísticas.

2.3 ALGORITMOS META-HEURÍSTICOS

Os algoritmos meta-heurísticos são algoritmos inspirados em processos naturais. Estas técnicas visam realizar uma busca eficiente sobre espaços de solução complexos e grandes. O fato de que meta-heurísticas conseguem resolver facilmente problemas de otimização não lineares, não convexos e com múltiplas funções objetivas, os torna ideais para otimização em sistemas de potência. A seguir, uma breve introdução a alguns desses algoritmos que são mais utilizados atualmente em FPO:

2.3.1 ALGORITMO GENÉTICO

O algoritmo genético é amplamente utilizado e é uma ferramenta poderosa para lidar com uma grande variedade de problemas de otimização. AGs são técnicas de otimização baseadas em seleção natural e evolução genética, projetadas para explorar grandes espaços de busca através da imitação de processos biológicos, como seleção, recombinação gênica, e mutação. A solução possível, encodada como um cromossomo, é avaliada por funções de avaliação, e a melhor solução é passada adiante para a próxima geração. Tais características permitem que os AGs resolvam tanto problemas de otimização com restrições quanto irrestritos.

No estudo [12] uma versão melhorada do algoritmo genético foi criada com o intuito de resolver problemas de despacho econômico com mais de uma opção de combustível. Esta abordagem supera métodos tradicionais ao promover soluções robustas para problemas de despacho econômico. Um outro método novo para melhorar a aplicação dos algoritmos genéticos em FPO foi introduzido em [13]. O método foca em escolher as tensões complexas iniciais nos geradores para manter as restrições violadas em um patamar mínimo, o que melhora o tempo computacional e a qualidade da solução. Testado em sistemas de teste padrão IEEE, o método mostra competitividade significativa em relação à técnicas existentes.

2.3.2 OTIMIZAÇÃO POR ENXAME DE PARTÍCULAS (PSO)

Desenvolvido originalmente em 1995, PSO é uma técnica de otimização estocástica baseada em população que se inspira no comportamento coletivo de aglomerados de pássaros ou peixes. PSO define um enxame de partículas, cada uma representa uma possível solução. Ao compartilhar experiências individuais e coletivas, estas partículas convergem para as regiões ótimas no domínio de busca. Cada partícula acha sua nova posição baseado nas experiências prévias individuais e das partículas vizinhas. Para obter melhores, soluções, o algoritmo muda a velocidade e posição das partículas até a convergência.

No estudo [14], PSO foi usado para lidar com o problema do despacho econômico. O trabalho se concentrou em unidades geradoras que exibiam efeitos ponto-de-válvula, ou seja, ondulação no custo de geração causada pela abertura gradual das válvulas de entrada de vapor nas turbinas, o que torna a curva custo-potência não linear e não suave. As simulações validaram a performance em um sistema IEEE de

30 nós com 6 unidades geradoras, com resultados satisfatórios e superiores a Programação Evolutiva.

A referência [15] apresenta um método de ajuste fino em parâmetros de sistemas de potência para resolver o FPO; a abordagem combina lógica fuzzy, algoritmo genético e PSO, com o objetivo de diminuir o custo de geração de potência ativa. O método híbrido foi testado num sistema IEEE modificado com 30 nós e os resultados mostraram que essa abordagem integrada é mais eficiente que os métodos existentes até então.

2.3.3 ALGORITMO EVOLUTIVO DIFERENCIAL (AED)

O ED é baseado em três mecanismos básicos: mutação, recombinação gênica, e seleção. Mutação produz novas candidatas a solução combinando as diferenças ponderadas de dois vetores gerados aleatoriamente em um terceiro vetor. Recombinação mistura vetores mutantes com vetores existentes para manter a diversidade populacional. Seleção mantém vetores com altos valores para a função objetiva, garantindo que a população melhore com o tempo. Em [16], o algoritmo evolutivo é usado em um problema de FPO que visa encontrar as melhores variáveis de controle para melhorar perfis de tensão, custo de combustível e estabilidade. A velocidade de convergência e a qualidade da solução foram comparadas com algoritmos tradicionais de otimização e com algoritmos meta-heurísticos como PSO e o algoritmo genético em um sistema de teste IEEE com 30 nós. O estudo reconhece que os melhores resultados do algoritmo evolutivo podem ser sensíveis aos parâmetros de controle em consideração e podem demandar calibração a depender do problema abordado, de modo que sistemas de potência complexos requerem algum nível de refinamento sobre o método ED básico.

3 METODOLOGIA

A metodologia adotada neste trabalho foi estruturada em duas etapas complementares: uma etapa conceitual e exploratória, desenvolvida durante o TCC I, com foco na revisão bibliográfica, formulações matemáticas, aprendizado das ferramentas e desenho do método de otimização; e uma etapa com foco experimental, prevista para o TCC II, que integrará o Algoritmo Genético (AG) com um motor de cálculo de fluxo de potência (OpenDSS) para realizar simulações completas de Fluxo de Potência Ótimo (FPO) multiobjetivo.

O objetivo final do projeto é propor, implementar e avaliar a performance do Algoritmo Genético na resolução do FPO multiobjetivo com inserção de energia renovável. Para isso, adotou-se os seguintes passos:

- Estudo do FPO e suas formulações.
- Análise crítica dos métodos clássicos e suas limitações frente a natureza do FPO.
- Escolha do Algoritmo Genético como meta-heurística principal, devido à sua flexibilidade, robustez e facilidade de mapeamento para o problema do FPO.
- Construção teórica do mapeamento entre variáveis do FPO e a estrutura genética dos indivíduos.
- Modelagem da geração eólica usando funções de Weibull.
- Estudo do OpenDSS e realização de testes iniciais de Fluxo de Potência em redes IEEE para validar a modelagem da geração eólica.
- Proposição de um fluxo de otimização envolvendo a ferramenta OpenDSS e sua interface em Python, o qual atuará como motor de cálculo de fluxo de potência, ou seja, produtor do conjunto das soluções em cada iteração do Fluxo de Potência Ótimo.

3.1 ALGORITMO GENÉTICO

Dentre os algoritmos meta-heurísticos mais utilizados na literatura, optou-se por focar no Algoritmo Genético devido a fatores como:

- Capacidade de lidar naturalmente com múltiplos objetivos, permitindo combinações como custo + perdas + perfil de tensão + emissões.
- Flexibilidade para codificar diferentes tipos de variáveis (contínuas, discretas e até variáveis híbridas), comum em problemas de FPO.
- Histórico e maturidade: O AG é uma das meta-heurísticas mais antigas e consolidadas, com vasta literatura no contexto do FPO. Na prática, isto

significa diversas possibilidades de implementação via softwares como Julia, Python ou MATLAB e uma base teórica e comparativa robusta.

- Lida bem com ótimos locais: Seus operadores probabilísticos mantêm a diversidade do conjunto de soluções a cada iteração, reduzindo o risco de convergência prematura, o que é uma vantagem em relação a algoritmos como o PSO, que podem concentrar partículas em regiões subótimas precocemente [\[17\]](#).

3.1.1 O AG EXPLICADO

Algoritmos genéticos são estratégias de busca estocásticas, iterativas, e de propósito geral baseadas nos princípios de genética populacional e a teoria da evolução por seleção natural. Essas estratégias empregam as noções de acasalamento e sobrevivência do mais apto para obter a solução de um problema [\[18\]](#). O pioneiro do Algoritmo Genético foi Holland [\[19\]](#), o qual estava interessado em simular sistemas adaptativos naturais em software. O algoritmo é usado em um enorme escopo de disciplinas, incluindo ciências sociais, ciências contábeis, biologia e engenharia, especialmente em aplicações que envolvem otimização e machine learning, sendo particularmente bom em problemas nos quais os algoritmos tradicionais não performam como desejado. Goldberg [\[20\]](#) escolhe 4 características que, para ele, diferenciam o AG dos métodos tradicionais:

- AG trabalha com uma codificação das variáveis do problema, não com as variáveis em si.
- AG busca uma população de soluções potenciais, não apenas uma potencial solução.
- AG avalia soluções potenciais através de uma função de aptidão, sem precisar de derivadas ou informações adicionais da função objetivo.
- AG usa operações probabilísticas ao invés de determinísticas.

Durante a execução do algoritmo, um número fixo de potenciais soluções é mantido, esse conjunto é chamado de população. A população inicial é gerada aleatoriamente. Cada solução da população constitui um cromossomo, que por sua vez é uma codificação binária dos parâmetros do problema sob consideração. Particularmente, no caso do FPO, um cromossomo poderia codificar informações sobre a potência ativa nos nós de geração, a tensão nos nós de carga e o TAP dos transformadores.

O fato de que o AG usa uma população de potenciais soluções significa que muitas regiões do espaço de busca multidimensional podem ser exploradas simultaneamente. Então ainda que o AG opere cegamente, isto é, não usa informações acerca das derivadas da função objetivo para orientar sua busca, a

convergência ainda assim pode ser acelerada devido a esse paralelismo que proporciona uma busca simultânea em diversas regiões do espaço de busca. A população evolui iterativamente e cada iteração corresponde a uma “geração”. Assim como na seleção natural, o papel da evolução é eliminar soluções “inaptas” e promover soluções “aptas”. A cada geração, soluções potenciais são avaliadas por uma função de aptidão baseada na função objetivo do problema original e elencadas de acordo com sua aptidão. A nova população resultante guarda elementos da população da geração anterior, mas também contém novos cromossomos geneticamente modificados a partir de cromossomos da geração anterior, por meio de operadores genéticos. Conforme o seguimento do processo evolutivo, cada geração sucessiva é composta de soluções mais aptas. Após um número significativo de gerações, o AG alcança uma população que não pode mais ser melhorada de acordo com os critérios da função de aptidão. Neste ponto, o melhor cromossomo dessa população codifica a solução para o problema verdadeiro, a qual deve estar em um nível aceitável de proximidade em relação a solução ótima.

Alguns problemas do AG são a escolha do tamanho populacional (trade-off entre recursos computacionais e performance) e das taxas de recombinação e mutação (operadores que serão explicados adiante), os quais são essencialmente parâmetros experimentais, embora investigações práticas possam dar uma direção. Além disso, como boa parte dos algoritmos de otimização, o AG não tem garantia de obter a solução ótima, podendo convergir prematuramente em um ponto onde as soluções potenciais param de melhorar.

3.1.2 OPERADORES GENÉTICOS

Para que uma nova população se forme em uma determinada iteração, é necessário a aplicação de operadores genéticos sobre a população antiga. Tais operadores genéticos são análogos a operações encontradas na natureza:

- **Seleção (ou Reprodução):** a forma mais comum de seleção utiliza uma técnica conhecida como seleção proporcional. Neste método, cromossomos são probabilisticamente selecionados da antiga população. A seleção é aleatória, mas o peso da escolha de um determinado cromossomo é proporcional ao valor normalizado da função de aptidão aplicada neste cromossomo. Dessa forma, soluções potenciais da antiga população mais bem ranqueadas de acordo com a função de aptidão tem maiores chances de permanecerem na nova população.
- **Recombinação (Crossover):** O operador anterior seleciona novas soluções potenciais. No entanto, sem a criação de novos cromossomos, o AG iria rapidamente convergir para uma população contendo as melhores soluções da população inicial, o que não é necessariamente ótimo, considerando a

vastidão do espaço de busca e outras possíveis soluções que não foram exploradas, isto é, nunca fizeram parte da população e nunca foram avaliadas segundo a função de aptidão. Para lidar com isso, o operador probabilístico de Recombinação é introduzido. Dois cromossomos são escolhidos aleatoriamente da nova população de acordo com taxas probabilísticas definidas pelo usuário. Um ponto aleatório em cada cromossomo é escolhido para que eles se dividam em duas partes a partir desse ponto, a parte correspondente a cada cromossomo é cruzada em um novo cromossomo. Assim, dois cromossomos pais se juntam para produzir dois cromossomos filhos que os substituem, representando duas soluções candidatas do problema na nova iteração.

- **Mutação:** Assim como as duas operações anteriores, também é probabilística. Um cromossomo da nova população é escolhido aleatoriamente de acordo com uma probabilidade definida pelo usuário e um único bit, em uma posição aleatória do cromossomo, é flipado. Isso garante exploração de diferentes áreas do espaço de busca e geralmente ocorre em uma taxa muito menor que a recombinação.

Esses operadores são a base do algoritmo genético, mas podem ser ligeiramente e convenientemente modificados de acordo com a aplicação particular do algoritmo e a estrutura do problema.




Figura 3 – Fluxograma do Algoritmo Genético.

```

BEGIN
  seleção, recombinação, mutação: OPERADORES
  geração = 0
  inicializa população(geração)
  WHILE condição
    geração += 1
    população(geração) = seleção(população(geração - 1))
    recombinação(população(geração))
    mutação(população(geração))
  END
END

```

Figura 4 - Pseudocódigo do Algoritmo Genético.

3.1.3 MAPEAMENTO DAS VARIÁVEIS DO FPO PARA O AG

3.1.3.1 FUNÇÕES OBJETIVO E RESTRIÇÕES

Inicialmente, consideremos as 3 funções objetivo que se deseja minimizar:

- Custo de geração:

$$f_1 = \sum_{i=1}^{N_G} (a_i P_{Gi}^2 + b_i P_{Gi} + c_i) \text{ (US$/h)}$$
- Perfil de tensão nas barras:

$$f_2 = \sum_{i=1}^{N_L} |V_i - V_{\text{ref}}| \text{ (pu)}$$
- Quantidade de poluentes emitidos:

$$f_3 = \sum_{i=1}^{N_G} (\alpha_i + \beta_i P_{Gi} + \gamma_i P_{Gi}^2) \text{ (ton/h)}$$

Esses objetivos podem ser combinados em uma única função objetivo agregada, de forma a equilibrar critérios econômicos e elétricos do sistema, com pesos definidos por simulação a fim de gerar uma quantidade conclusiva de resultados. Como cada função tem unidade diferente, é necessária sua normalização antes de combiná-las, para que elas possam ser somadas e ponderadas coerentemente pelos pesos. Uma possibilidade de normalização para cada função objetiva é:

$$f'_i = \frac{f_i - f_i^{\min}}{f_i^{\max} - f_i^{\min}}$$

Onde $f_i^{\min}$ é o menor valor esperado da função objetivo (melhor desempenho) e $f_i^{\max}$ é o maior valor esperado da função objetivo (pior desempenho). Para cada uma das funções, existem algumas estratégias para definir $f_i^{\min}$ e $f_i^{\max}$, de modo a manter todas as funções em uma mesma ordem de grandeza: usar valores típicos da literatura ou limites conhecidos a depender do caso de estudo e da estrutura da rede em análise, usar o menor e maior valor obtido da função durante a execução do AG e atualizar conforme a população evolui – comum em AGs adaptativos ou usar o resultado de testes iniciais após ter rodado o AG algumas vezes. A função objetivo agregada é, portanto, $F(x) = w_1 f'_1 + w_2 f'_2 + w_3 f'_3$.

As restrições do problema compreendem:

- Balanço de potência ativa e reativa nas barras:

$$P_{Gi} - P_{Di} - V_i \sum_{j=1}^{N_b} V_j (G_{ij} \cos \phi_{ij} + B_{ij} \sin \phi_{ij}) = 0$$

$$Q_{Gi} - Q_{Di} - V_i \sum_{j=1}^{N_b} V_j (G_{ij} \sin \phi_{ij} - B_{ij} \cos \phi_{ij}) = 0$$

- Limites de geração, tensão e térmico:

$$P_{Gi}^{\min} \leq P_{Gi} \leq P_{Gi}^{\max}$$

$$Q_{Gi}^{\min} \leq Q_{Gi} \leq Q_{Gi}^{\max}$$

$$V_i^{\min} \leq V_i \leq V_i^{\max}$$

$$P_{line}^{ij} \leq P_{line}^{ij, \max}$$

A resolução do FPO por meio do AG requer a conversão do modelo matemático original, que contém restrições de igualdade e desigualdade, em uma função escalar compatível com o processo evolutivo. Para tal, adota-se uma função penalizada, que combina as funções objetivo originais com termos adicionais responsáveis por punir violações das restrições operacionais, de modo que quanto maior o grau de violação, maior o valor da função penalizada e, portanto, menor a qualidade da solução.

Assim, se o problema tiver i restrições de igualdade e j restrições de desigualdade do tipo $h(X) \leq 0$, onde X é o vetor das variáveis de controle do problema, a função objetivo resultante será:

$$F'(x) = F(x) + \sum_{i=1}^{n_g} \lambda_i |g_i(x)| + \sum_{j=1}^{n_h} \mu_j \max(0, h_j(x))^2$$

Onde λ_i e u_j são fatores de penalização, $|g_i(x)|$ penaliza violações de igualdade, e $\max(0, h_j(x))^2$ penaliza violações de desigualdade.

Expressando-se todas as variáveis de controle em valor por unidade (pu), não há diferenças significativas de escala que justifiquem a normalização das restrições. Dessa forma, a etapa de normalização é aplicada apenas às funções objetivo, quando estas envolvem grandezas de natureza distinta, como custo de geração (R\$/h) e emissões de poluentes (kg/h), garantindo que todas contribuam de forma balanceada na função agregada.

Como o GA geralmente beneficia soluções mais aptas, ou seja, que **maximizam** a função de aptidão, enquanto o objetivo do FPO é **minimizar** os custos, desvios de tensão e emissões de poluentes, é necessário inverter a função penalizada para construir a função fitness:

$$Fitness(x) = \frac{1}{F'(x)}$$

Com as 3 funções objetivas e todas as restrições do problema incorporadas a função fitness de base para rodar o algoritmo genético, ainda é necessário discutir o a codificação das variáveis originais do FPO em variáveis do problema evolutivo.

3.1.3.2 REPRESENTAÇÃO E CODIFICAÇÃO DAS VARIÁVEIS NO AG

No Algoritmo Genético, cada indivíduo da população representa uma solução candidata para o problema. Essa solução é expressa por um cromossomo, que é um vetor de genes, cada gene correspondendo a uma variável de decisão do problema. Assim, no contexto do FPO, os genes podem representar, por exemplo:

- Potências ativa e reativa geradas (P_{Gi} e Q_{Gi})
- Tensão nos nós de carga (V_i)
- Tap dos transformadores (T_j)
- Ângulos de fase (θ_i)

Cada cromossomo representa, portanto, um ponto no espaço de busca, ou seja, um vetor de variáveis de decisão do problema: uma possível configuração operacional do sistema elétrico.

Existem 3 abordagens principais para representar os cromossomos no GA: codificação binária, codificação não binária (os genes podem ser representados por números inteiros ou números reais) e codificação mista. A forma clássica do GA proposta por Holland [\[19\]](#) prevê codificação binária, de modo que qualquer

representação diferente adapta o uso dos operadores genéticos, que tradicionalmente eram aplicados bit a bit. Como muitos detalhes de implementação serão abstraídos por software e a maioria das variáveis do FPO são números reais, é natural usar a codificação dos genes em números reais para evitar erros de arredondamento e obter uma convergência mais rápida [21]. Se o sistema de estudo tiver transformadores, a codificação mista poderá ser utilizada para a obtenção de um modelo mais fiel às restrições do sistema, dado que o Tap dos transformadores são variáveis discretas.

3.2 MODELAGEM DA GERAÇÃO EÓLICA

A presença crescente de geração eólica nos sistemas elétricos introduz um componente significativo de variabilidade e incerteza operacional – a produção eólica depende diretamente de variáveis meteorológicas, especialmente da velocidade do vento. Assim, qualquer estudo de FPO que incorpore fontes renováveis intermitentes deve levar essa grandeza em consideração para que as soluções obtidas sejam realistas e operacionalmente viáveis. Nesta seção, é apresentada a modelagem que caracteriza a geração eólica ao longo do trabalho, considerando sua descrição estatística, e o modelo de conversão vento para potência.

3.2.1 CONVERSÃO DA VELOCIDADE DO VENTO EM POTÊNCIA

Diversos trabalhos na literatura modelam a velocidade do vento em um determinado local por uma distribuição de Weibull [22], definida por dois parâmetros: o parâmetro de forma k e o parâmetro de escala λ , sendo a função distribuição de probabilidade dada por $f(v) = \frac{k}{\lambda} \left(\frac{v}{\lambda}\right)^{k-1} \exp\left(-\left(\frac{v}{\lambda}\right)^k\right)$, onde v representa a velocidade instantânea do vento, k é o parâmetro de forma que controla a distribuição da dispersão, e λ é o parâmetro de escala, relacionado a velocidade média observada na região de interesse. Valores típicos encontrados na literatura para regiões de bom potencial eólico variam k entre 1,8 a 3 e λ entre 6 e 10m/s. Neste relatório, para uma demonstração prática do impacto da geração renovável no fluxo de potência, foram adotados $k = 2$ e $\lambda = 8\text{m/s}$, parâmetros compatíveis com regiões de vento moderado, como as regiões ao norte do Brasil, e utilizados amplamente em trabalhos de referência.

Com os parâmetros definidos, a velocidade do vento pode ser amostrada ao longo de um horizonte temporal conforme a função de probabilidade acima. Para tal, foi construída uma série com 24 amostras, número escolhido para se adequar ao

modelo temporal escolhido nas simulações do *OpenDSS*, que representa o impacto eólico durante o período de um dia, o qual será explicado adiante. A série foi gerada utilizando a biblioteca Numpy da linguagem Python, através do método *numpy.random.weibull(k, size)*. O método gera uma amostra de tamanho *size* de números aleatórios segundo a função probabilidade Weibull de um parâmetro (*k*). Para obter uma amostra que também leva em conta o parâmetro de escala, basta multiplicar o retorno da função pelo parâmetro de escala:

$$V = \lambda \cdot \text{numpy.random.weibull}(k, \text{size})$$

Onde V é o vetor de velocidades do vento em m/s, λ é o parâmetro de escala da função Weibull, k é o parâmetro de forma e $\text{size} = 24$. O passo seguinte consiste em converter cada valor v_t ($t = 1, 2, \dots, 300$) da série temporal de velocidades na potência correspondente fornecida pela turbina eólica. Para esse fim, utilizou-se uma representação típica encontrada na literatura da curva de potência de aerogeradores, a qual relaciona a velocidade do vento com a potência elétrica extraída [23]. Essa curva é caracterizada por 4 regiões fundamentais:

- Cut-in: para velocidades inferiores a $v_{ci} = 3\text{m/s}$, a turbina permanece desligada, resultando em potência nula.
- Região de rampa: entre $v_{ci} = 3\text{m/s}$ e a velocidade nominal $v_r = 12\text{m/s}$, a potência aumenta de forma aproximadamente linear.
- Região nominal: entre $v_r = 12\text{m/s}$ e a velocidade de desligamento por segurança $v_{co} = 25\text{m/s}$, a potência se mantém no valor nominal.
- Cut-out: acima de $v_{co} = 25\text{m/s}$, a turbina é desligada para evitar danos estruturais, retornando a potência nula.

A curva pode ser aproximada pela seguinte função por partes:

$$P(v) = \begin{cases} 0, & v < v_{ci}, \\ P_{\text{nom}} \cdot \frac{v - v_{ci}}{v_r - v_{ci}}, & v_{ci} \leq v < v_r, \\ P_{\text{nom}}, & v_r \leq v \leq v_{co}, \\ 0, & v > v_{co}. \end{cases}$$

Figura 5 - Função por partes para representar a conversão de velocidade do vento para potência eólica gerada pelas turbinas.

Aplicando essa função a cada elemento do vetor V obtém-se a série temporal de potência P_t . Para utilização no *openDSS*, a potência deve ser normalizada em relação ao valor nominal do aerogerador, de modo que o software aplique o vento como um multiplicador sobre a potência definida como nominal do gerador. Assim, temos um vetor formado por uma série de multiplicadores do tipo:

$$m_t = \frac{P_t}{P_{nom}}, 0 \leq m_t \leq 1, t = (1, 2, \dots, 24)$$

Este vetor, quando exportado para um arquivo txt ou csv, constitui a curva de carga da geração eólica e está pronto para ser consumido pelo *OpenDSS*.

```

script.py >...
1  import numpy as np
2
3  # 1. PARÂMETROS DA DISTRIBUIÇÃO DE WEIBULL
4  k = 2.0 # parâmetro de forma
5  lam = 8.0 # parâmetro de escala (m/s)
6  N = 300 # número de amostras (ex.: 300 s de simulação ou 300 intervalos)
7
8  # 2. SÉRIE TEMPORAL DE VELOCIDADES DO VENTO
9  velocidades = lam * np.random.weibull(k, size=N)
10
11 # 3. CURVA DE POTÊNCIA DA TURBINA (NORMALIZADA)
12 # - cut-in: 3 m/s
13 # - rated: 12 m/s
14 # - cut-out: 25 m/s
15 # - potência normalizada entre 0 e 1
16 def potencia_turbina(v):
17     if v < 3:
18         return 0.0
19     elif v < 12:
20         # rampa linear entre cut-in e rated
21         return (v - 3) / (12 - 3)
22     elif v <= 25:
23         return 1.0
24     else:
25         return 0.0
26
27 mult = np.array([potencia_turbina(v) for v in velocidades])
28
29 # 4. SALVAR O LOADSHAPE EM CSV
30 np.savetxt("windshape.csv", mult, fmt="%.3f")
31
32 print("Arquivo windshape.csv gerado com sucesso!")

```

Figura 6 – Script .py para geração do vetor dos multiplicadores a partir das amostras aleatórias de velocidade do vento oriundas da função distribuição de probabilidade de Weibull.

3.3 OPENDSS E A INTERFACE EM PYTHON PY-DSS-INTERFACE

Tendo a formulação matemática da geração eólica, é necessário incorporar isso ao modelo elétrico que será utilizado nas simulações deste trabalho daqui em diante. Para tal, lançaremos mão do software *OpenDSS* (Open Distribution System Simulator), uma ferramenta amplamente utilizada em pesquisas envolvendo análise de redes, avaliação de impactos de geração distribuída e estudos de fluxo de potência. O *OpenDSS* permite a definição de modelos monofásicos, trifásicos ou mistos, e oferece suporte nativo a elementos de geração renovável através das curvas de carga.

Embora o *OpenDSS* possua uma linguagem própria baseada em scripts, a interação direta por meio de arquivos pode se tornar limitada quando se deseja realizar simulações iterativas, análises paramétricas ou integrar o simulador a algoritmos de otimização (como o Algoritmo Genético). Para contornar isso, utilizou-se a biblioteca em Python *py-dss-interface* [24], que disponibiliza uma interface para total controle dos comandos do *OpenDSS*. Através dessa interface, é possível utilizar o *OpenDSS* como uma máquina de cálculo de fluxo de potência, alterar parâmetros em tempo real e executar simulações em um loop Python, o que habilita a integração do modelo elétrico com técnicas de otimização, como os algoritmos evolutivos que serão utilizados no desenvolvimento do FPO em TCC II.

3.3.1 GERAÇÃO EÓLICA NO OPENDSS

A geração eólica modelada na seção anterior pode ser incorporada ao *OpenDSS* por meio da criação de um objeto do tipo *LoadShape* no software e a associação deste a um elemento do tipo *Generator*, ambos inseridos no sistema IEEE em análise. O *LoadShape* é o mecanismo nativo do *OpenDSS* para representar perfis temporais de potência ativa e reativa.

Inicialmente, o vetor dos multiplicadores m_t mencionado na seção 3.2.1 foi exportado em formato .csv, de modo que cada linha representa o valor do multiplicador no instante t . Assim, definimos o *LoadShape* utilizando a biblioteca *py-dss-interface* a partir do comando:

```
dss.text("New Loadshape.WindShape npts=24 sinterval=1 mult=(file=windshape.csv)")
```

Figura 7 - Instrução para definir um elemento do tipo *LoadShape* no *OpenDSS*.

Onde *npts* define o número de pontos do perfil temporal, *sinterval* define o intervalo de tempo entre as amostras e *mult* recebe o arquivo .csv que contém os multiplicadores que definem o *LoadShape*. Finalmente, o *LoadShape* pode ser associado a um gerador eólico através do comando:

```
dss.text("New Generator.WindGen bus1=450 kv=4.16 kw=2000 pf=1 daily=windShape")
```

Figura 8 - Instrução para definir um elemento do tipo *Generator* no *OpenDSS*.

Onde os parâmetros definem a barra a qual o gerador será conectado, sua tensão e potência nominais, fator de potência (1 no caso de geração eólica) e a associação ao *LoadShape* previamente definido.

4 RESULTADOS

Para validar a modelagem matemática da geração eólica e o ambiente experimental, faremos simulações com um caso simples de teste do IEEE de 4 barras chamado 4Bus-YY-Bal, disponível na biblioteca do *OpenDSS*. O modelo tem uma barra de suprimento operando a 12,47kV modelada com alta potência de curto-circuito para aproximar um barramento infinito, uma linha trifásica conectando a barra de suprimento a um transformador trifásico Y-Y de 12,47/4,16kV e uma segunda linha trifásica de 4,16kV conectando o transformador a uma carga trifásica de potência nominal de 5,4MW e fator de potência de 0,9.




Figura 5 – Caso 4-Bus-YY-Bal do IEEE.

4.1 CASO 1 - GERAÇÃO NAS BARRAS, SIMULAÇÃO ESTÁTICA

Inicialmente, consideremos uma geração eólica de potência constante igual a nominal. O gerador foi colocado em diferentes barras do sistema a fim de comparar as perdas totais e o perfil de tensão em cada um dos casos após a resolução do Fluxo de Potência. Faremos isso para $P_{nom} = 500\text{kW}$ e $P_{nom} = 1000\text{kW}$.

Results

Barra	P_nom_kW	Perdas_kW	P_ativa_total_kW	V_min_pu	V_max_pu
0	0	569.175	5969.085	0.798	1
n2	500	541.365	2286.868	0.804	1
n3	500	550.976	5450.896	0.801	1
n4	500	486.395	5453.487	0.811	1
n2	1000	534.197	1416.092	0.809	1
n3	1000	534.369	4934.299	0.804	1
n4	1000	410.413	4924.427	0.824	1

Figura 6 – Perdas e perfil de tensão variando de acordo com a localização do gerador eólico e sua potência nominal.

A Tabela apresenta os resultados das simulações estáticas realizadas no sistema de teste com diferentes valores de potência nominal (500 kW e 1000 kW) e distintas localizações da geração eólica. A análise das perdas elétricas e dos níveis de tensão revela um comportamento esperado.

No caso base, sem geração eólica, o circuito apresenta perdas significativas (aprox. 569 kW) e uma tensão mínima relativamente baixa (0,798 pu), resultado esperado para a carga distante da barra de suprimento.

A inserção de geração na barra *n2*, próxima à fonte, provoca apenas uma redução moderada nas perdas e um leve aumento na tensão mínima. Isso ocorre porque a maior parte das perdas está associada aos trechos de 4,16 kV próximos à carga, que continuam altamente carregados mesmo após a injeção de potência em *n2*.

O maior benefício ocorre com a instalação da geração em *n4*, barra onde está conectada a carga principal. Nesse cenário, as perdas totais sofrem a maior redução entre todos os casos, e a tensão mínima aumenta de forma mais expressiva. A injeção local de potência reduz o fluxo vindo do barramento de suprimento, melhorando simultaneamente eficiência e perfil de tensão.

Os resultados confirmam que o impacto da geração eólica aumenta significativamente quando ela é instalada próxima às cargas que pretende suprir, validando a modelagem da geração renovável no software e o ambiente de simulação.

4.2 CASO 2 - GERAÇÃO EM N4, SIMULAÇÃO DINÂMICA

A segunda validação consiste em uma simulação dinâmica, num período de 24 horas, de uma geração eólica instalada na barra *n4*, para observarmos os gráficos das perdas e das tensões durante o período.




Figura 7 – Perdas ao longo do dia sem geração eólica e com geração eólica instalada.




Figura 8 - Redução das perdas ao longo do dia.




Figura 9 - Redução percentual das perdas ao longo do dia.




Figura 10 - Tensão mínima em pu ao longo do dia.



Figura 11 - Elevação da tensão mínima causada pela geração eólica.

Os gráficos obtidos na simulação dinâmica permitem avaliar como a geração eólica afeta o comportamento temporal do sistema ao longo das 24 horas analisadas. Observando o perfil das perdas totais, nota-se uma tendência clara de redução sempre que a potência eólica disponível aumenta, resultado esperado pelo alívio dos fluxos de potência ao longo dos alimentadores de 4,16 kV. A curva apresenta oscilações coerentes com o *LoadShape* aplicado: quanto maior os multiplicadores (maior potência disponível) menor as perdas, e quanto menor os multiplicadores (menos potência disponível) maior as perdas: circuito volta a operar próximo do caso base, sem geração renovável.

O comportamento das tensões também reflete essa dinâmica. A tensão mínima tende a se elevar nos intervalos de maior geração eólica, especialmente devido à injeção local em n4, reduzindo a queda de tensão ao longo do alimentador. A oscilação simultânea das curvas de tensão mínima e perda total evidencia a relação inversa entre carregamento da rede e nível de tensão: quando a geração reduz o fluxo vindo da barra de suprimento, as tensões sobem e as perdas diminuem.

Assim, os resultados dinâmicos corroboram as conclusões do caso estático: a geração eólica localizada na barra n4 melhora de forma consistente tanto a eficiência quanto o perfil de tensão do sistema. A análise temporal revela que esse benefício é diretamente proporcional à disponibilidade instantânea de vento, destacando a importância de se considerar perfis realistas de geração em estudos de planejamento e operação. [\[25\]](#)

5 - PRÓXIMOS PASSOS

O TCC II terá como objetivo principal a implementação completa e a validação do método de otimização proposto neste trabalho, integrando o Algoritmo Genético (AG) ao cálculo do Fluxo de Potência Ótimo (FPO) em redes com inserção de fontes renováveis. Enquanto o TCC I concentrou-se na fundamentação teórica, na modelagem e validação experimental dos modelos e em análises preliminares do comportamento elétrico do sistema, o TCC II será dedicado à construção do algoritmo de otimização propriamente dito, à realização de simulações em larga escala e à análise quantitativa dos resultados.

A primeira etapa do TCC II consistirá na implementação computacional do Algoritmo Genético, incorporando os operadores de seleção, crossover e mutação, bem como os mecanismos de tratamento de restrições definidos teoricamente no TCC I.

Na sequência, será realizada a integração entre o AG e o *OpenDSS*, que atuará como o motor de simulação elétrica responsável por resolver o fluxo de potência a cada avaliação de fitness. Para cada indivíduo gerado pelo AG, o *OpenDSS* será acionado para calcular tensões, fluxos, perdas e demais grandezas necessárias ao cálculo das funções objetivo.

Além disso, será realizada a calibração dos parâmetros do Algoritmo Genético, tais como tamanho da população, taxas de crossover e mutação, critérios de parada e estratégias de seleção. Essa calibração será conduzida por meio de testes sistemáticos, buscando equilibrar qualidade das soluções, robustez e tempo computacional.

Após a implementação e calibração do método, serão conduzidos estudos de caso tanto em sistemas de teste padrão IEEE quanto em casos maiores adaptados a realidade do sistema brasileiro. Os resultados do AG serão então comparados com soluções obtidas por métodos convencionais de FPO e outras implementações meta-heurísticas na literatura, quando disponíveis, de modo a avaliar ganhos em desempenho, qualidade da solução, tempo e capacidade de lidar com múltiplos objetivos e com a inserção de fontes renováveis. Os resultados serão analisados criticamente, permitindo identificar vantagens, limitações e possibilidades de melhoria do método.

6 - CONCLUSÃO PARCIAL

Este trabalho apresentou o desenvolvimento do TCC I, cujo foco esteve na construção da base teórica, metodológica e computacional necessária para a resolução do problema do Fluxo de Potência Ótimo (FPO) em formulação multiobjetivo com inserção de fontes renováveis, por meio do uso de algoritmos meta-heurísticos, em especial o Algoritmo Genético (AG). Ao longo do relatório, foram discutidos os principais conceitos relacionados ao fluxo de potência, às técnicas clássicas de otimização e às abordagens meta-heurísticas.

A definição das funções objetivo, das restrições elétricas e operacionais, e o mapeamento entre as variáveis do problema de FPO e a estrutura do AG, consolidou a base teórica do relatório. Além disso, a modelagem da geração renovável e a definição do *OpenDSS* como motor de simulação constituíram passos fundamentais para viabilizar a integração entre o algoritmo de otimização e a avaliação elétrica das soluções candidatas.

Os resultados parciais apresentados, obtidos a partir de simulações preliminares de fluxo de potência, permitiram validar o ambiente computacional adotado, confirmar o comportamento esperado do sistema elétrico em termos de perfil de tensão e perdas quando submetido a geração renovável, e identificar variáveis críticas para o processo de otimização. Esses resultados evidenciam que a metodologia proposta é consistente e tecnicamente viável, criando uma base robusta para a aplicação efetiva do Algoritmo Genético no TCC II.

Dessa forma, o TCC I cumpre seu papel de etapa preparatória, organizando os fundamentos teóricos, estruturando a metodologia e estabelecendo os primeiros resultados experimentais. No TCC II, o enfoque será direcionado à implementação completa do método de otimização, à realização de estudos de caso mais aprofundados e à análise quantitativa dos ganhos proporcionados pela abordagem proposta.

REFERÊNCIAS

- A.A.A. E. Ela, M. A. Abido, and S. R. Spea**, “Optimal power flow using differential evolution algorithm,” *Electric Power Systems Research*, vol. 80, no. 7, pp. 878–885, Jul. 2010.
- Adefarati, T., & Bansal, R. C.** (2017). Integration of renewable distributed generators into the distribution system: A review. *Renewable & Sustainable Energy Reviews*.
- Attia, H. A.** (2024). Comparative analysis of GA, PSO, and DE algorithms for optimal power flow problems. *Energy Reports*, vol. 10, pp. 123–132.
- Bienstock, D., & Verma, A.** (2019). Strong NP-hardness of AC power flows feasibility. *Operations Research Letters*, vol. 47, no. 6, pp. 494–501, Nov.
- Carta, J. A., Ramírez, P., & Velázquez, S.** (2009). A review of wind speed probability distributions in the power generation field. *Renewable & Sustainable Energy Reviews*.
- Chen, S.-D., & Chen, J.-F.** (1997). A new algorithm based on the Newton–Raphson approach for real-time emission dispatch. *Electric Power Systems Research*, vol. 40, no. 2, pp. 137–141, Feb.
- Chiang, C.-L.** (2005). Improved genetic algorithm for power economic dispatch of units with valve-point effects and multiple fuels. *IEEE Transactions on Power Systems*, vol. 20, no. 4, pp. 1690–1699, Nov.
- Franco, J. F., Ochoa, L. F., & Romero, R.** (2018). AC OPF for smart distribution networks: An efficient and robust quadratic approach. *IEEE Transactions on Smart Grid*, vol. 9, no. 5, pp. 4613–4623, Sep.

Galletly, J. E. (1992). An overview of genetic algorithms. *Kybernetes*, vol. 21, no. 6, pp. 26–30. doi:10.1108/eb005943

Goldberg, D. E. (1989). *Genetic Algorithms in Search, Optimization and Machine Learning*. Addison-Wesley, Reading, MA.

Holland, J. H. (1975). *Adaptation in Natural and Artificial Systems*. University of Michigan Press, Ann Arbor, MI.

Kulworawanichpong, T. (2010). Simplified Newton–Raphson power-flow solution method. *International Journal of Electrical Power & Energy Systems*, vol. 32, no. 6, pp. 551–558, Jul.

Kumar, S., & Chaturvedi, D. K. (2013). Optimal power flow solution using fuzzy evolutionary and swarm optimization. *International Journal of Electrical Power & Energy Systems*, vol. 47, pp. 416–423, May.

Lai, L. L., Nieh, T. Y., Vujatovic, D., Ma, Y. N., Lu, Y. P., Wang, Y. W., & Braun, H. (2005). Particle swarm optimization for economic dispatch of units with non-smooth input–output characteristic functions. In *Proceedings of the 13th International Conference on Intelligent Systems Applications to Power Systems*, Nov., p. 5.

Manwell, J. F., McGowan, J. G., & Rogers, A. L. (2010). *Wind Energy Explained: Theory, Design and Application*. Wiley.

Momoh, J. A. (1989). A generalized quadratic-based model for optimal power flow. In *Proceedings of the International Conference on Systems, Man and Cybernetics*, Nov., pp. 261–271.

Mouassa, S., Alateeq, A., Alassaf, A., Bayindir, R., Alsaleh, I., & Jurado, F. (2024). Optimal power flow analysis with renewable energy resource uncertainty using dwarf mongoose optimizer: Case of ADRAR isolated electrical network. *IEEE Access*, vol. 12, pp. 10202–10218.

Olofsson, M., Andersson, G., & Söder, L. (1995). Linear programming based optimal power flow using second order sensitivities. *IEEE Transactions on Power Systems*, vol. 10, no. 3, pp. 1691–1697, Aug.

Paulo Radatz. Canal no YouTube.

Rong, Q., Hu, P., Yu, Y., Wang, D., Cao, Y., & Xin, H. (2025). Virtual external perturbation-based impedance measurement of grid-connected converter. *IEEE Transactions on Industrial Electronics*, vol. 72, no. 3, pp. 2644–2654, Mar.

Todorovski, M., & Rajičić, D. (2006). An initialization procedure in solving optimal power flow by genetic algorithm. *IEEE Transactions on Power Systems*, vol. 21, no. 2, pp. 480–487, May.

Wang, H., Murillo-Sanchez, C. E., Zimmerman, R. D., & Thomas, R. J. On computational issues of market-based optimal power flow. *IEEE Transactions* (dados incompletos no original).

Wang, X., Guo, Q., Tu, C., Che, L., Xu, Z., Xiao, F., Li, T., & Chen, L. (2025). A comprehensive control strategy for F-SOP considering three-phase imbalance and economic operation in ISLDN. *IEEE Transactions on Sustainable Energy*, vol. 16, no. 1, pp. 149–159, Jan.

Wang, Z., Younesi, A., Liu, M. V., Guo, G. C., & Anderson, C. L. (2023). AC optimal power flow in power systems with renewable energy integration: A review of formulations and case studies. *IEEE Access*, vol. 11, pp. 102681–102712.

Zhang, Y. et al. (2023). Real-coded genetic algorithm for large-scale optimal power flow considering renewable uncertainties. *Applied Soft Computing*, vol. 139, p. 110159.